INSTRUKSI TUGAS PRAKTIKUM

PySpark Fundamentals • Building Batch Data Pipelines • Structured Streaming with Spark

Dokumen ini berisi panduan pengerjaan tiga tugas praktikum. Kerjakan secara berurutan agar konsep dasar PySpark menjadi bekal untuk membangun pipeline batch dan kemudian memproses data streaming.

Ketentuan Umum

- Kerjakan secara mandiri. Pahami fungsi setiap bagian kode, bukan hanya menjalankan notebook.
- Lengkapi semua bagian TODO. Jika ada kode yang belum lengkap, isi sesuai instruksi pada notebook.
- Jalankan setiap cell secara berurutan. Periksa hasilnya dan pastikan tidak ada error yang belum ditangani.
- Catat troubleshooting. Jika terjadi error, tuliskan penyebab dan langkah perbaikannya secara singkat.
- Simpan output notebook. Pastikan notebook memuat kode dan hasil eksekusi yang diperlukan untuk penilaian.
- Format nama file: `Nama_Tugas1.ipynb`, `Nama_Tugas2.ipynb`, dan `Nama_Tugas3.ipynb`.

TUGAS 1 — PySpark Fundamentals

Studi kasus: Analisis data harga cryptocurrency menggunakan PySpark.

Tujuan

Memahami pembuatan SparkSession dan DataFrame, melakukan transformasi data dasar, membuat agregasi, menggabungkan data, serta menyimpan hasil ke format Parquet.

Langkah pengerjaan

- Inisialisasi SparkSession.
- Buat DataFrame dari data cryptocurrency yang tersedia di notebook.
- Pilih kolom yang dibutuhkan dan lakukan filter sesuai instruksi.
- Tambahkan kolom konversi harga USD ke IDR menggunakan kurs latihan yang ditentukan di notebook.
- Lakukan agregasi untuk memperoleh rata-rata dan harga maksimum sesuai kelompok yang diminta.
- Urutkan hasil dan lakukan inner join dengan data kategori.
- Simpan hasil akhir ke format Parquet dan verifikasi hasil penyimpanan.
- Jawab pertanyaan interpretasi: jelaskan temuan utama dari hasil analisis.

Komponen penilaian

Komponen	Bobot
Penyelesaian kode dasar dan DataFrame	40%
Transformasi dan agregasi	30%
Penyimpanan Parquet	10%
Interpretasi hasil	20%

TUGAS 2 — Building Batch Data Pipelines with Spark

Studi kasus: Membangun pipeline batch untuk data transaksi e-commerce.

Tujuan

Membangun alur pemrosesan batch yang mencakup pemeriksaan data mentah, pembersihan, validasi, transformasi, agregasi, pelaporan kualitas data, dan penyimpanan hasil.

Langkah pengerjaan

- Inisialisasi SparkSession dan baca data transaksi yang disediakan.
- Periksa jumlah baris dan kondisi awal dataset.
- Hilangkan duplikasi berdasarkan transaction_id.
- Validasi data: `transaction_id` tidak boleh null, `quantity` harus lebih dari 0, `unit_price` harus tersedia dan tidak negatif, serta status transaksi harus `PAID`.
- Hitung nilai pendapatan (revenue) berdasarkan quantity dan unit_price, lalu olah kolom tanggal sesuai instruksi.
- Buat ringkasan per kategori yang mencakup jumlah transaksi, total unit, dan total pendapatan.
- Buat ringkasan pendapatan harian.
- Susun laporan kualitas data yang menunjukkan jumlah data awal, duplikasi, data valid, dan data yang dikeluarkan sesuai struktur notebook.
- Simpan dataset bersih dan tabel ringkasan ke format Parquet, lalu baca kembali untuk memverifikasi hasil.
- Jawab pertanyaan refleksi tentang keputusan pembersihan dan kualitas output pipeline.

Komponen penilaian

Komponen	Bobot
Deduplication dan validasi	25%
Transformasi dan perhitungan revenue	20%
Agregasi kategori dan harian	20%
Laporan kualitas data	15%
Penyimpanan Parquet	10%
Interpretasi hasil	10%

TUGAS 3 — Structured Streaming with Spark

Studi kasus: Case Study A — CoinGecko → PostgreSQL → Kafka → Spark.

Tujuan

Memahami pemrosesan data secara streaming menggunakan Spark Structured Streaming, termasuk membaca pesan dari Kafka, mem-parsing JSON, membersihkan data, melakukan agregasi berbasis window, dan mengelola checkpoint.

Prasyarat dan catatan

- Tugas ini mengasumsikan lingkungan PostgreSQL, Kafka, dan Spark telah tersedia dan berjalan.
- Pastikan producer yang mengambil data dari CoinGecko telah mengirim pesan ke topic Kafka `crypto_stream`.
- CoinGecko API bukan sumber push-streaming langsung dalam skenario ini; producer melakukan polling API, kemudian mengirimkan data melalui alur yang disiapkan.
- Gunakan lokasi checkpoint yang persisten dan unik untuk setiap streaming query. Jangan gunakan checkpoint yang sama untuk query yang berbeda.

Langkah pengerjaan

- Inisialisasi SparkSession dan definisikan schema JSON untuk data coin, price, dan time.
- Baca stream dari Kafka topic `crypto_stream`.
- Parse kolom `value` Kafka sebagai JSON menggunakan schema yang telah dibuat.
- Ubah kolom waktu menjadi tipe timestamp dan filter data yang tidak valid.
- Terapkan watermark 2 menit pada event time.
- Buat agregasi berbasis window untuk memperoleh rata-rata dan harga maksimum per coin.
- Jalankan query dengan console sink untuk memeriksa output.
- Periksa status query streaming yang aktif dan pastikan checkpoint dikonfigurasi.
- Jika diminta, simpan output ke Parquet menggunakan checkpoint terpisah.
- Jawab pertanyaan refleksi tentang event time, watermark, checkpoint, dan tantangan streaming.

Komponen penilaian

Komponen	Bobot
Spark, koneksi Kafka, dan schema	20%
Parsing JSON dan pembersihan	20%
Agregasi window	25%
Streaming query dan checkpoint	20%
Refleksi dan pemahaman konsep	15%

Checklist sebelum mengumpulkan

- Semua TODO utama telah diselesaikan.
- Notebook dapat dijalankan sesuai prasyarat masing-masing tugas.
- Output penting terlihat dan tidak ada error yang dibiarkan tanpa penjelasan.
- Pertanyaan interpretasi/refleksi telah dijawab dengan kalimat sendiri.
- Nama file sudah mengikuti format yang ditentukan.